

Specifikacija projekta: Prepoznavanje teksta napisanog latiničnim i ćiriličnim pismom (Handwriting-OCR)

Opis problema

Prepoznavanje i analiza teksta sa fotografija predstavljaju kompleksan zadatak zbog brojnih izazova koji se mogu pojaviti.

Tekstovi mogu biti prikazani u različitim veličinama, stilovima, bojama i fontovima, što otežava standardizovanu detekciju i tačno prepoznavanje sadržaja.

Fotografije teksta često su snimljene u različitim uslovima osvetljenja i na šarenolikim pozadinama. Ove razlike mogu izazvati promene u kontrastu između teksta i pozadine, što dodatno otežava proces identifikacije.

Takođe, tekst na fotografijama može biti oštećen, deformisan ili delimično prekriven drugim objektima. Ovi faktori mogu uticati na pouzdanost sistema za prepoznavanje i otežati izdvajanje tačnih informacija.

Cilj ovog projekta je da se razvije robustan i efikasan model koji će moći automatski da prepozna i precizno analizira tekst sa fotografija, uprkos varijacijama u okruženju i kvalitetu prikaza.

Specifikacija programa

Tok rešavanja problema:

- Pretprocesiranje podataka:
 - Uređivanje i ispravljanje grešaka među podacima dobijenih iz skupova podataka.
 - Kombinovanje skupova podataka.
- Podela učitanih skupa podataka na trening i validacioni skup.
- Obučavanje i validacija konvolucione neuronske mreže (CNN) nad napravljenim alfabetom i skupom podataka.
- Testiranje neuronske mreže nad testnim skupom i evaluacija svih dobijenih rezultata.
- Kreiranje grafičkog interfejsa kako bi korisnici mogli lako da koriste dobijeni model.

Tok prepoznavanja karaktera na slici sa tekстом:

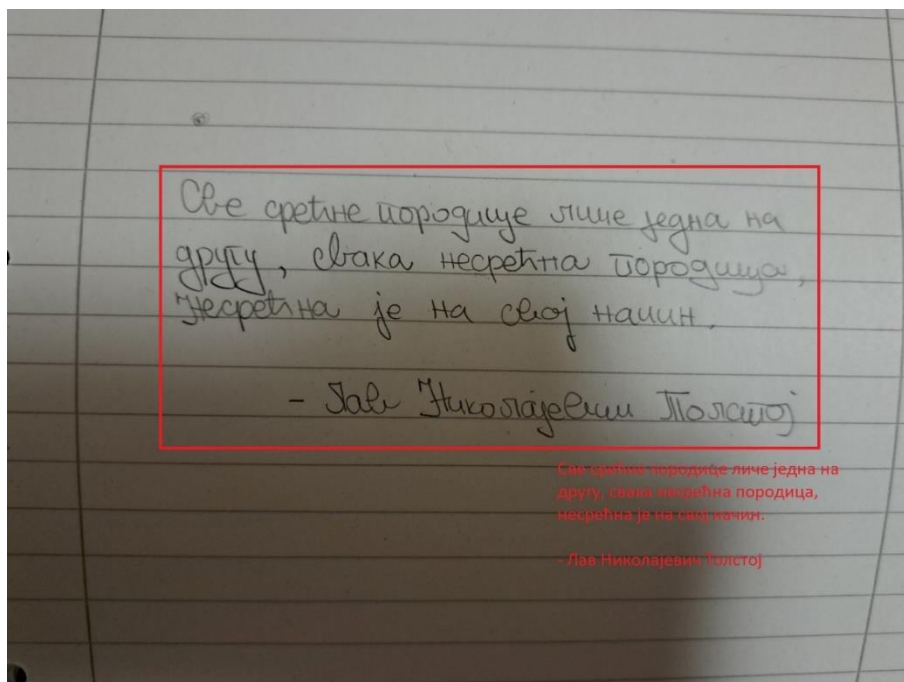
- Učitavanje i priprema slike:
 - Učitavanje ulazne slike koja sadrži tekst i primena algoritama kako bi se zarotirana slika pravilno pozicionirala i iskrivljena slika ispravila.
 - Pretvaranje slike u binarni format (crno-bela slika) radi lakše obrade.
- Pronalaženje regiona od interesa (ROI - Region of Interest):
 - Identifikacija i selekcija regiona na slici za koje se pretpostavlja da sadrže tekstualne karaktere i spajanje dijakritika sa njihovim karakterima.

- Sortiranje prepoznatih regiona po apscisnoj osi.
- Analiza udaljenosti između regiona (karaktera):
 - Izračunavanje udaljenosti između susednih prepoznatih regiona. Ove udaljenosti su ključne za kasniju segmentaciju reči i dodavanje razmaka.
- Klasterovanje udaljenosti (K-Means):
 - Primena K-Means algoritma na izračunate udaljenosti. Cilj je grupisati udaljenosti u dva klastera: jedan za razmak između karaktera unutar iste reči i drugi za razmak između reči.
- Priprema ulaza za neuronsku mrežu:
 - Transformacija prepoznatih regiona (karaktera) u format pogodan za ulaz u neuronsku mrežu (npr. normalizacija veličine, konverzija u vektor piksela).
- Prepoznavanje karaktera (CNN - Convolutional Neural Network):
 - Korišćenje prethodno istrenirane veštačke neuronske mreže (CNN) za predviđanje karaktera za svaki prepoznati region.
- Prikaz rezultata sa razmacima:
 - Na osnovu rezultata K-Means klasterovanja udaljenosti, kombinovanje prepoznatih karaktera sa odgovarajućim razmacima (između karaktera i između reči) radi formiranja prepoznatog teksta.

Tehnologije za izradu projekta

- Python će biti korišćen za implementaciju algoritma, zbog lakoće korišćenja i širokog spektra biblioteka za mašinsko učenje i vizualizaciju podataka (NumPy, OpenCV, matplotlib, Keras), kao i biblioteka za pravljenje grafičkog korisničkog interfejsa.
- Za dokumentovanje i analizu će biti korišćen Jupyter Notebook.

Primer gotovog rešenja



Reference i literatura

1. Repozitorijum predmeta Soft Computing: <https://github.com/ftn-ai-lab/sc-2024>
2. Repozitorijum sa rešenjima predmeta Soft Computing: <https://github.com/neshko31/sc-2024-resenja>
3. Vežbe predmeta NANS

Skupovi podataka

- OpenWrite Dataset – Version 2: <https://www.kaggle.com/datasets/nenadlukic/openwrite-dataset/versions/2>